



Benutzerhandbuch

KI-Plattform — Konfiguration, Betrieb und Nutzung

Produkt	kv-brain — lokale, mandantenfähige KI-Plattform
Zielgruppen	Administratoren, Server-Betrieb, Anwenderinnen und Anwender
Betrieb	On-Premise (NVIDIA DGX Spark), vollständig lokal
Lokales LLM	Qwen3 32B via Ollama; Embedding nomic-embed-text
Zugang	Browser: Chat unter / · Verwaltung unter /admin
Stand	Juni 2026 · Branch feat/white-label-mono

ST COMPUTER GmbH

Inhalt

1	Einleitung	4
1.1	Für wen ist dieses Handbuch?	4
1.2	Die drei Module	4
2	Überblick und Architektur	5
2.1	Architekturschema	5
2.2	Komponenten	5
2.3	Ablauf einer Anfrage	5
3	Anmeldung und Rollenkonzept	7
3.1	Zugangsadressen	7
3.2	Single Sign-On (Keycloak)	7
3.3	Rollen und Sichtbarkeitsgruppen	7
3.4	Erste Anmeldung als Administrator	7
Teil A — Administration (Verwaltungs-UI)		8
4	Dokumente und Wissensbasis	9
4.1	Wissensdatenbanken anlegen	9
4.2	Dokumente hochladen	9
4.3	Suchen, filtern, Sammelaktionen	9
5	Nutzerverwaltung	10
5.1	Nutzer anlegen und bearbeiten	10
5.2	Rollen und Gruppen zuweisen	10
5.3	Modelle pro Nutzer freigeben	10
5.4	Active Directory (AD/LDAP)	10
6	KI-Modelle	11
6.1	Modell-Katalog (Tab Einstellungen)	11
6.2	Lokales Modell herunterladen	11
6.3	Externe Modelle und API-Keys	11
7	Monitoring und E-Mail-Alarm	12
7.1	Systemstatus	12
7.2	E-Mail-Alarm (SMTP)	12
7.3	Letzte Ereignisse	12
8	System steuern	13
9	Sicherung (Backup) und Wiederherstellung (Restore)	14
9.1	Was wird gesichert?	14
9.2	Backup auf NAS einrichten (Tab Einstellungen)	14
9.3	Wiederherstellung (Restore)	14
10	HTTPS und Hostname	15
11	Dokumentensystem (ELO) anbinden	16
12	Audit-Protokoll	17
Teil B — Server-Betrieb (Kommandozeile)		18
13	Befehlsübersicht	19
14	Update einspielen	20
14.1	Plattform aktualisieren	20

14.2 Betriebssystem (DGX) aktualisieren	20
15 Nach Netz- oder IP-Wechsel	21
Teil C — Nutzung (für Anwenderinnen und Anwender)	22
16 Anmelden und Oberfläche	23
17 Modell auswählen — lokal oder extern	24
18 Die Wissensbasis nutzen	25
18.1 Gute Antworten bekommen	25
19 Das Dokumentensystem (ELO) nutzen	26
20 Datenschutz aus Anwendersicht	27
21 Datenschutz und Compliance (Grundsätze)	28
22 Fehlerbehebung	29
23 Glossar	30

1 Einleitung

kv-brain ist eine KI-Plattform, die vollständig auf Ihrem eigenen Server läuft. Mitarbeitende können in natürlicher Sprache mit einem Sprachmodell arbeiten, Fragen an freigegebene Wissensdatenbanken stellen und — sofern angebunden — ein Dokumentenmanagementsystem (ELO) durchsuchen. Es werden keine Daten ungefragt an Dritte übertragen.

1.1 Für wen ist dieses Handbuch?

Teil	Zielgruppe	Inhalt
Teil A	Administratoren	Verwaltungs-UI: Wissensbasis, Nutzer, Modelle, Monitoring, Backup, HTTPS, ELO
Teil B	Server-Betrieb / IT	Kommandozeile: Update, Migration, Sicherung/Restore, Netzwechsel
Teil C	Anwenderinnen/Anwender	Tägliche Nutzung: Chat, Modelle, Wissensbasis, Dokumentensystem

1.2 Die drei Module

- Wissensbasis (RAG): Antworten auf Basis Ihrer eigenen, hochgeladenen Dokumente — mit Quellenangaben und rechtegeprüft nach Sichtbarkeitsgruppen.
- Externe KI-Modelle (optional): OpenAI/Anthropic, standardmäßig deaktiviert, nur nach bewusster Freigabe durch die Administration.
- Dokumentensystem (ELO, optional): Lesezugriff auf ein angebundenes ELO-DMS über einen Assistenten.

2 Überblick und Architektur

Die Plattform besteht aus mehreren Diensten (Docker-Containern), die zusammenarbeiten. Für die tägliche Nutzung müssen Sie diese nicht kennen — für Administration und Betrieb hilft der Überblick.

2.1 Architekturschema

Das Schema zeigt den Aufbau von oben (Zugriff per Browser) nach unten (Daten und KI). Grün gestrichelt ist die On-Premise-Grenze: Alles darin läuft lokal auf dem DGX Spark. Orange gestrichelt und außerhalb dieser Grenze sind die optionalen externen Systeme (Cloud-Modelle und das ELO-Bestandssystem).




Abbildung 1: Systemarchitektur der kv-brain-Plattform

2.2 Komponenten

Dienst	Zweck (vereinfacht)
Open WebUI	Die Oberfläche, in der Anwender chatten und die Wissensbasis nutzen
API-Gateway	Zentrale Steuerung, Anmeldeprüfung, Verwaltungs-UI unter /admin
RAG-Service	Durchsucht die Dokumente, prüft Rechte, erstellt Antworten mit Quellen
LLM-Service	Leitet Anfragen an das lokale Modell (oder optional an externe)
Ollama	Die KI-Engine, die das Sprachmodell ausführt (lokal, mit GPU)
Keycloak	Anmeldung, Benutzer, Rollen und Gruppen (Single Sign-On)
PostgreSQL	Datenbank: Dokument-Index, Einstellungen, Protokoll, Keycloak-Daten
MinIO	Speicher für die Original-Dokumente
ELO-Connector	Verbindung zum ELO-Dokumentensystem (nur lesend)
Caddy	Verschlüsselte Verbindung (HTTPS) nach außen

2.3 Ablauf einer Anfrage

1. Anmeldung: Der Browser meldet sich über Keycloak an (SSO) und erhält ein Token mit Rollen und Mandant (tenant_id).
2. Anfrage: Die Frage geht über Caddy an Open WebUI; die passende Pipe reicht das Token an das API-Gateway weiter.
3. Prüfung: Das API-Gateway prüft das Token, bestimmt tenant_id und Rollen und leitet an den richtigen Dienst.
4. Wissensbasis: Der RAG-Service sucht rechtegeprüft in PostgreSQL/pgvector, holt die Texte und lässt Ollama (lokal) eine Antwort mit Quellen formulieren.
5. Externe Modelle (nur falls freigegeben): Der LLM-Service leitet die Anfrage an OpenAI/Anthropic — in der Antwort klar als extern gekennzeichnet.
6. Dokumentensystem: Der ELO-Connector fragt das ELO-DMS lesend ab; Ollama formuliert die Antwort.
7. Rückweg: Die Antwort fließt denselben Weg zurück in den Browser.

Wichtig zu wissen

Wissensbasis (RAG) und Dokumentensystem (ELO) nutzen IMMER das lokale Modell.

Dokumenteninhalte verlassen das System unter keinen Umständen.

Die Datenbank enthält auch die Keycloak-Daten — eine Sicherung der Datenbank sichert damit Realm, Benutzer und Anmeldekonfiguration vollständig mit.

3 Anmeldung und Rollenkonzept

3.1 Zugangsadressen

Die Plattform ist über zwei Oberflächen erreichbar: den Chat (für Anwender) und die Verwaltung (für Administratoren). Im HTTPS-Betrieb laufen beide über den Hostnamen; im rein internen Betrieb ohne HTTPS direkt über die IP und den jeweiligen Port.

Zweck	Mit HTTPS (Hostname)	Intern ohne HTTPS (IP)
Chat (Anwender)	https://<hostname>	http://<IP>:3000
Verwaltung (Admin)	https://<hostname>/admin	http://<IP>:8000/admin
Keycloak-Konsole	https://<hostname>/auth/admin/	http://<IP>:8080/auth/admin/

Beispiel intern: http://192.168.126.25:8000/admin (Verwaltung) und http://192.168.126.25:3000 (Chat).

Hinweise

Die Verwaltung liegt unter /admin (mit Schrägstrich: /admin/). Die Wurzel http://<IP>:8000 ist tokengeschützt und zeigt 'Token fehlt' - das ist normal.
Die Keycloak-Konsole ist /auth/admin/ (Anmeldung 'admin' + KEYCLOAK_ADMIN_PASSWORD), nicht zu verwechseln mit der App-Anmeldeseite.

3.2 Single Sign-On (Keycloak)

Die Anmeldung erfolgt zentral über Keycloak. Wer angemeldet ist, kann Chat und Wissensbasis nutzen, ohne sich erneut anzumelden. Die Anmeldedaten kommen entweder aus lokal in Keycloak angelegten Konten oder — falls angebunden — aus dem Active Directory.

3.3 Rollen und Sichtbarkeitsgruppen

Rolle / Gruppe	Bedeutung
kv-admin	Administrator: voller Zugriff auf das Verwaltungs-UI
alle	Standard-Sichtbarkeitsgruppe (alle Mitarbeitenden)
GF / Verwaltung / Datenschutz	Sichtbarkeitsgruppen je Bereich
ESF BRB / Panel / Rehapro / my turn	Sichtbarkeitsgruppen je Projekt

Sichtbarkeitsgruppen steuern, welche Wissensdatenbanken eine Person sehen und durchsuchen darf. Sie werden zentral konfiguriert (in der .env über ACL_GROUPS) und stehen automatisch als Rollen, Auswahlfelder und Filter zur Verfügung.

3.4 Erste Anmeldung als Administrator

- Verwaltungs-UI öffnen: https://<hostname>/admin (intern: http://<ip>:8000/admin)
- Mit dem kv-admin-Konto anmelden (im Setup angelegt)
- Nach Rollenänderungen immer ab- und neu anmelden — Rollen stehen im Anmelde-Token

Wenn Tabs fehlen (Nutzer, Protokoll, Einstellungen)

Dann fehlt dem Konto die Rolle kv-admin. In der Keycloak-Konsole unter Users -> Role mapping die Rolle kv-admin (und alle) zuweisen, danach im Verwaltungs-UI ab- und neu anmelden.

Teil A — Administration (Verwaltungs-UI)

Das Verwaltungs-UI ist die zentrale Oberfläche für Administratoren. Es ist gegliedert in die Tabs Dokumente, Nutzer, Protokoll und Einstellungen. Ganz unten zeigt eine Fußzeile Version, Entwicklungsstand und die verwendete Branch.

4 Dokumente und Wissensbasis

4.1 Wissensdatenbanken anlegen

- Im Tab Dokumente lassen sich beliebig benannte Wissensdatenbanken anlegen (z.B. Verwaltung, ESF BRB, Rehapro).
- Über Zugriff legen Sie je Wissensdatenbank fest, welche Sichtbarkeitsgruppen sie sehen dürfen.
- Eine Person sieht und durchsucht nur Wissensdatenbanken, für die ihre Gruppe freigeschaltet ist.

4.2 Dokumente hochladen

Dokumente werden per Drag-and-Drop, als Ordner oder als ZIP-Archiv hochgeladen. Beim Hochladen wählen Sie die Ziel-Wissensdatenbank und die Sichtbarkeitsgruppe.

- 24 Formate werden verarbeitet, u.a. PDF, Word, Excel, PowerPoint, RTF, ODT/ODS, CSV, E-Mail (eml/msg), HTML und reiner Text.
- Gescannte PDFs und Bilder (PNG/JPG/TIFF) werden per Texterkennung (OCR) lesbar gemacht.
- Duplikate werden anhand des Inhalts erkannt und nicht doppelt aufgenommen.

4.3 Suchen, filtern, Sammelaktionen

- Die Dokumentliste lässt sich nach Name, Wissensdatenbank, Gruppe und Dateityp filtern und ist seitenweise navigierbar.
- Sammelaktionen (Bulk): mehrere Dokumente gleichzeitig verschieben, die Sichtbarkeit ändern oder löschen.

Compliance

Die Suche ist immer rechtegeprüft: In Antworten fließen nur Dokumente ein, für die die Gruppe der anfragenden Person eine Leseberechtigung hat.

5 Nutzerverwaltung

5.1 Nutzer anlegen und bearbeiten

- Im Tab Nutzer neue Konten mit Benutzername und Startpasswort anlegen.
- Bestehende Nutzer bearbeiten, Passwort zurücksetzen oder deaktivieren.
- Funktioniert mit und ohne Active-Directory-Anbindung.

5.2 Rollen und Gruppen zuweisen

Über Rollen weisen Sie einer Person die Sichtbarkeitsgruppen zu (welche Wissensdatenbanken sie nutzen darf) und ggf. die Administratorrolle kv-admin. Änderungen wirken nach der nächsten Anmeldung.

5.3 Modelle pro Nutzer freigeben

Über Modelle legen Sie fest, welche KI-Modelle eine Person verwenden darf — zusätzlich zu den für alle freigegebenen. So lassen sich z.B. externe Modelle nur für einzelne Personen freischalten.

5.4 Active Directory (AD/LDAP)

Im Tab Einstellungen kann eine Windows-Domäne über das Active Directory angebunden werden (nur lesend). Angebundene Konten erscheinen nach dem ersten Login in der Nutzerliste; Rollen und Gruppen werden weiterhin im Verwaltungs-UI vergeben.

Empfehlung

Immer mindestens ein lokales kv-admin-Konto behalten (Break-Glass), damit die Administration auch bei AD-Störungen möglich bleibt.

6 KI-Modelle

6.1 Modell-Katalog (Tab Einstellungen)

- Aktiv: schaltet ein Modell grundsätzlich nutzbar.
- Für alle Nutzer: gibt ein aktives Modell für alle frei (sonst nur individuell pro Nutzer).
- Das lokale Modell (Qwen3 32B) ist standardmäßig aktiv und für alle freigegeben.

6.2 Lokales Modell herunterladen

Unter Lokales Modell herunterladen kann ein weiteres Ollama-Modell auf den Server geladen werden.

11. Modellnamen eintragen (z.B. qwen3:14b, gemma3, llama3.3) — Namen siehe ollama.com/library
12. Herunterladen klicken; der Fortschritt wird angezeigt (große Modelle dauern einige Minuten)
13. Nach Abschluss erscheint das Modell oben in der Liste und kann dort aktiviert/freigegeben werden

Neu geladene Modelle sind zunächst deaktiviert — die Freigabe ist ein bewusster Schritt. Es läuft immer nur ein Download gleichzeitig.

6.3 Externe Modelle und API-Keys

Externe Modelle (OpenAI/Anthropic) sind standardmäßig deaktiviert. Zur Nutzung werden unter API-Keys die Schlüssel hinterlegt (verschlüsselt gespeichert, nie wieder angezeigt) und das gewünschte Modell aktiviert.

Datenschutz bei externen Modellen

Externe Modelle übertragen Nutzereingaben an Dritte außerhalb der Plattform. Aktivierung nur nach Freigabe durch den Datenschutzbeauftragten. In jeder Antwort sind externe Modelle klar als extern gekennzeichnet. Wissensbasis und ELO nutzen niemals externe Modelle.

7 Monitoring und E-Mail-Alarm

7.1 Systemstatus

Im Tab Einstellungen prüft der Systemstatus alle Dienste, die geladenen Modelle und den Keycloak-Service-Account. Dies ist die erste Anlaufstelle bei Problemen — jeder rote Punkt enthält einen Lösungshinweis.

7.2 E-Mail-Alarm (SMTP)

- Unter Monitoring SMTP-Server, Absender und Empfänger hinterlegen und Alarm aktivieren.
- Über Testnachricht senden die Konfiguration prüfen.
- Bei Ausfällen oder fehlgeschlagenen Backups wird automatisch eine E-Mail versendet.

7.3 Letzte Ereignisse

Eine Liste der jüngsten Status-Änderungen und Fehler (z.B. Dienst kurz nicht erreichbar, Backup fehlgeschlagen) — ohne Inhalte, nur Metadaten.

8 System steuern

Im Tab Einstellungen unter System steuern lassen sich direkt aus dem Browser ausführen:

- Dienste neu starten — startet die Plattform-Container neu (z.B. nach Konfigurationsänderungen).
- Server neu starten / herunterfahren — steuert den gesamten DGX.

Mit Bedacht verwenden

Diese Aktionen sind root-äquivalent, daher nur für kv-admin verfügbar und werden im Audit-Protokoll vermerkt. Nach 'Server herunterfahren' ist die Plattform erst nach physischem/Remote-Einschalten wieder erreichbar.

9 Sicherung (Backup) und Wiederherstellung (Restore)

9.1 Was wird gesichert?

- Datenbank (Dokument-Index, Wissensdatenbanken, Einstellungen, Protokoll, Keycloak).
- MinIO — die Original-Dokumente.
- Die .env — die Konfiguration inkl. Secrets.

9.2 Backup auf NAS einrichten (Tab Einstellungen)

14. NAS-Freigabe (URL) eintragen, z.B. //192.168.1.10/backup/drk-ki
15. Benutzer und Passwort des NAS-Freigabekontos eingeben (Passwort wird verschlüsselt gespeichert)
16. Verbindung testen — schreibt eine Testdatei und löscht sie wieder
17. Zeitplan aktivieren: täglich oder wöchentlich + Uhrzeit (bei wöchentlich zusätzlich Wochentag), dann Speichern

Der Stand der letzten erfolgreichen Sicherung wird oben in der Karte angezeigt. Zusätzlich wird stets lokal gesichert; schlägt der NAS-Upload fehl, bleibt die lokale Sicherung erhalten und es erscheint ein Ereignis.

Einrichtung auf dem Server (einmalig)

Der geplante Lauf benötigt einen Cron-Dispatcher und smbclient für den Upload:

```
sudo apt install -y smbclient
sudo bash scripts/backup.sh --install
```

Der Dispatcher prüft alle 15 Minuten den im UI hinterlegten Zeitplan.

9.3 Wiederherstellung (Restore)

Ein Voll-Restore stellt das gesamte System aus einem Backup-Satz wieder her. Da er Dienste stoppt und die Datenbank neu aufbaut, läuft er bewusst über die Kommandozeile (kein UI-Button).

```
# Vom NAS (neuester Stand; Passwort wird abgefragt):
bash scripts/restore.sh --nas //192.168.1.10/backup/drk-ki --user backup-user

# Bestimmter Stand:
bash scripts/restore.sh --nas //... --user U --ts 2026-06-24_0230

# Aus lokaler Sicherung:
bash scripts/restore.sh --local /var/backups/drk-ki
```

Ablauf: .env zurückspielen (die bisherige wird als .env.pre-restore.<Stand> gesichert), Datenbank neu aufbauen und einspielen (inkl. Keycloak), MinIO ersetzen, alle Dienste starten. Anschließend gleicht das Skript automatisch IP und Keycloak-Redirect-URLs an die aktuelle Umgebung an und führt einen Smoke-Test aus — so startet das System sicher wieder.

Empfehlung

Den Restore einmal testweise durchspielen, damit im Ernstfall sicher ist, dass NAS-Pfad und Backup-Satz sauber zurückkommen. Bei HTTPS-Betrieb danach:

```
python3 scripts/set_host.py <hostname> --https
```

10 HTTPS und Hostname

Im Tab Einstellungen unter HTTPS / Öffentlicher Hostname wird der Hostname gepflegt, unter dem die Plattform per HTTPS erreichbar ist. Das Zertifikat wird automatisch über Let's Encrypt ausgestellt und erneuert.

- Voraussetzung: DNS-Eintrag zeigt auf den Server; Ports 80 und 443 sind erreichbar.
- Beim Speichern werden die Keycloak-Redirect-URIs automatisch ergänzt.
- Die endgültige Umstellung erfordert einen einmaligen Befehl auf dem Server (wird nach dem Speichern angezeigt): `python3 scripts/set_host.py <hostname> --https`

Rein internes Netz

Ohne Internet-Zugang kann Let's Encrypt keine Challenge durchführen. Dann Caddy auf eine interne Zertifizierungsstelle umstellen und deren Root-Zertifikat per Gruppenrichtlinie verteilen.

11 Dokumentensystem (ELO) anbinden

Im Tab Einstellungen unter ELO-Dokumentensystem werden die Verbindungsdaten gepflegt: REST-Basis-URL sowie Zugangsdaten (Tomcat und/oder REST-API). Passwörter werden verschlüsselt gespeichert und nie zurückgegeben.

- Über Verbindung testen wird automatisch ermittelt, mit welchem Zugangsdaten-Paar die ELO-API antwortet.
- Die Anbindung ist ausschließlich lesend.

Namensauflösung

Nutzt die ELO-URL einen internen Hostnamen, müssen ELO_SERVER_HOST und ELO_SERVER_IP in der .env gesetzt sein, damit der Connector den Namen auch ohne internen DNS auflöst (reboot- und update-fest).

12 Audit-Protokoll

Der Tab Protokoll listet administrative Aktionen (z.B. Nutzer angelegt, Modell aktiviert, Einstellung geändert) mit Zeitpunkt und handelnder Person. Protokolliert werden ausschließlich Metadaten — niemals Frage- oder Dokumentinhalte.

Teil B — Server-Betrieb (Kommandozeile)

Dieser Teil richtet sich an die IT, die den Server betreut. Alle Befehle werden im Projektverzeichnis ausgeführt (cd ~/drk-mv-ki-plattform).

13 Befehlsübersicht

Aufgabe	Befehl
Status aller Dienste	<code>docker compose ps</code>
Protokoll eines Dienstes	<code>docker compose logs --tail=50 api-gateway</code>
Alles starten (nach Reboot/Stop)	<code>docker compose up -d</code>
Dienst neu bauen + starten	<code>docker compose up -d --build api-gateway</code>
Gesundheitscheck	<code>python3 scripts/smoke_test.py</code>
DB-Schema nachziehen	<code>bash scripts/migrate.sh</code>
Nach IP-/Netzwechsel	<code>python3 scripts/set_host.py</code>
Sicherung (Probelauf)	<code>sudo bash scripts/backup.sh</code>
Wiederherstellung	<code>bash scripts/restore.sh --nas ... --user ...</code>

14 Update einspielen

14.1 Plattform aktualisieren

```
cd ~/drk-mv-ki-plattform
sudo bash scripts/backup.sh          # Sicherung vorher
git pull
bash scripts/migrate.sh              # DB-Schema idempotent nachziehen
docker compose up -d --build         # geänderte Dienste neu bauen
python3 scripts/smoke_test.py        # muss grün sein
```

14.2 Betriebssystem (DGX) aktualisieren

```
sudo apt update && sudo apt full-upgrade -y
sudo reboot
# nach dem Reboot:
cd ~/drk-mv-ki-plattform && docker compose up -d
python3 scripts/smoke_test.py
```

Wichtig

Die Container starten nach einem Reboot von selbst (restart: unless-stopped).
NUR nach einem bewussten 'docker compose down' starten sie NICHT automatisch —
dann immer mit 'docker compose up -d' abschließen.

15 Nach Netz- oder IP-Wechsel

Bei fester IP ist nach einer einmaligen Änderung nichts weiter nötig. Falls sich die IP doch ändert, genügt ein Befehl — er erkennt die neue IP, korrigiert KEYCLOAK_PUBLIC_URL und die Redirect-URLs und startet die betroffenen Dienste neu:

```
python3 scripts/set_host.py                # interne IP automatisch
python3 scripts/set_host.py <hostname> --https # öffentlicher Hostname (HTTPS)
```

Teil C — Nutzung (für Anwenderinnen und Anwender)

Dieser Teil beschreibt die tägliche Arbeit mit kv-brain im Browser. Sie benötigen nur Ihre Anmeldedaten — alles andere läuft im Hintergrund.

16 Anmelden und Oberfläche

18. Die Adresse der Plattform im Browser öffnen — mit HTTPS: `https://<hostname> · intern ohne HTTPS: http://<IP>:3000`
19. Auf der Anmeldeseite mit Benutzername und Passwort anmelden
20. Danach öffnet sich die Chat-Oberfläche

Links wählen Sie oben das gewünschte Modell, in der Mitte führen Sie das Gespräch, frühere Unterhaltungen finden Sie in der Seitenleiste.

17 Modell auswählen — lokal oder extern

Oben in der Modellauswahl stehen je nach Freigabe verschiedene Einträge. Achten Sie auf die Kennzeichnung:

Auswahl	Bedeutung
Lokales Modell (z.B. Qwen3 32B, lokal)	Läuft komplett auf dem Server. Keine Daten verlassen das Haus. Standard.
Wissensbasis (lokal)	Beantwortet Fragen aus den freigegebenen Dokumenten, mit Quellen — immer lokal.
Dokumentensystem (ELO)	Durchsucht das ELO-DMS (sofern angebunden) — immer lokal.
Externes Modell (extern!)	Sendet Ihre Eingaben an einen Drittanbieter. Nur nutzen, wenn freigegeben.

Bewusst lokal oder extern arbeiten

Modelle mit dem Zusatz 'extern!' übertragen Ihre Eingaben an einen Cloud-Anbieter. Für vertrauliche Inhalte immer ein lokales Modell verwenden.

18 Die Wissensbasis nutzen

Mit der Wissensbasis stellen Sie Fragen zu den Dokumenten Ihrer Organisation und erhalten Antworten mit Quellenangaben.

21. Ein Wissensbasis-Modell wählen (z.B. 'Wissensbasis — alle')
22. Frage in normaler Sprache stellen, z.B. 'Welche Frist gilt für ...?'
23. Die Antwort nennt die verwendeten Quellen — so ist sie nachvollziehbar

Was Sie sehen — und was nicht

Sie erhalten nur Antworten aus Wissensdatenbanken, für die Ihre Gruppe freigeschaltet ist. Fragen zu nicht freigegebenen Inhalten werden mit einem Hinweis beantwortet, dass dazu keine freigegebenen Informationen vorliegen.

18.1 Gute Antworten bekommen

- Konkret fragen: Nennen Sie Zeitraum, Bereich oder Dokumentart, wenn relevant.
- Nachfragen ist erlaubt: Sie können die Antwort präzisieren lassen ('Fasse das kürzer', 'Nenne die Paragraphen').
- Quellen prüfen: Bei wichtigen Auskünften die angegebene Quelle gegenlesen.

19 Das Dokumentensystem (ELO) nutzen

Sofern angebunden, durchsuchen Sie mit dem ELO-Assistenten das Dokumentenmanagementsystem in natürlicher Sprache, z.B. 'Wie viele Rechnungen aus 2026 gibt es?' oder 'Finde Rechnungen von Firma X'. Die Antwort nennt die gefundenen Dokumente als Quelle. Der Zugriff ist nur lesend.

20 Datenschutz aus Anwendersicht

- Ihre Eingaben werden nicht gespeichert oder ausgewertet (kein Prompt-Logging).
- Lokale Modelle und die Wissensbasis verarbeiten alles ausschließlich auf dem Server.
- Nur ausdrücklich als 'extern!' gekennzeichnete Modelle senden Eingaben an Dritte.
- Sie sehen nur Inhalte, für die Ihre Gruppe berechtigt ist.

21 Datenschutz und Compliance (Grundsätze)

- Kein Prompt-Logging — Nutzereingaben werden nie gespeichert oder analysiert.
- Mandantentrennung — die Zuordnung (`tenant_id`) stammt ausschließlich aus dem Anmelde-Token; Row-Level Security in der Datenbank.
- Rechtegeprüfte Generierung — RAG nutzt nur Dokumente mit aktiver Leseberechtigung der Gruppe.
- Externe Modelle nur bewusst — standardmäßig deaktiviert, Aktivierung nur durch Admin (DSB-Freigabe), in jeder Antwort gekennzeichnet.
- Secrets nie im Code — nur über die `.env`; Passwörter im UI werden verschlüsselt gespeichert und nie zurückgegeben.

22 Fehlerbehebung

Symptom	Ursache / Lösung
Login: 'nicht erreichbar' / falsche Adresse	Nach Netzwechsel: python3 scripts/set_host.py ausführen
'Invalid parameter: redirect_uri'	set_host.py ausführen (registriert Redirect-URLs für die aktuelle IP)
'Invalid username or password'	Passwort in der Keycloak-Konsole zurücksetzen (Temporary: Off)
Tabs Nutzer/Protokoll/Einstellungen fehlen	Rolle kv-admin zuweisen, danach ab- und neu anmelden
Nutzer-Tab: 'Service-Account nicht nutzbar'	python3 scripts/setup_keycloak.py erneut ausführen
Chat langsam / keine Antwort	Systemstatus prüfen; Modell muss in Ollama geladen sein
RAG: 'keine freigegebenen Informationen'	Gruppen-/Zugriffsrechte prüfen; nach Änderung neu anmelden
ELO 'nicht verfügbar'	ELO-Verbindung testen; ELO_SERVER_IP in .env prüfen
NAS-Test schlägt fehl	URL //server/freigabe, Benutzer/Passwort und Erreichbarkeit prüfen
Nach Reboot nichts erreichbar	cd ~/drk-mv-ki-plattform && docker compose up -d

Erste Anlaufstelle bleibt immer: Verwaltungs-UI -> Einstellungen -> Systemstatus.

23 Glossar

Begriff	Erklärung
RAG	Retrieval-Augmented Generation — Antworten auf Basis eigener Dokumente
LLM	Large Language Model — das Sprachmodell (hier Qwen3 32B, lokal)
Ollama	Software, die das Sprachmodell auf dem Server ausführt
Keycloak	Anmelde-/Rechteverwaltung (Single Sign-On)
Sichtbarkeitsgruppe	Steuert, welche Wissensdatenbanken eine Person nutzen darf
Embedding	Mathematische Repräsentation von Text für die Vektorsuche
Tenant	Mandant — die organisatorische Trennung der Daten
.env	Konfigurationsdatei mit allen Einstellungen und Secrets